PRESENTACIÓN

PROYECTO DE TRANSFORMACIÓN DIGITAL

Lectura, limpieza e inserción de datos



LA IDEA DE PROYECTO

Nuestro cliente, Adalab, está inmerso en un proceso de transformación digital y nos ha pedido crear unos métodos que les sean útiles para coger sus datos, limpiarlos e insertarlos en una base de datos.

BENEFICIOS PARA EL CLIENTE

1

ORDEN

Al crear una base de datos dónde exista una tabla por cada tipo de dato, podrán almacenar toda la información de su empresa. 2

AUTOMATIZACIÓN

Con las funciones que se han creado, podrán añadir nuevos registros a la base de datos sin necesidad de volver a crear todas las operaciones necesarias. 3

CONSULTAS

Con este producto, podrán realizar búsquedas de una forma fácil y cómoda, sin necesidad de procesos técnicos complicados.

OBJETIVOS

CREACIÓN DE UNA BASE DE DATOS

2 LIMPIEZA E INSERCIÓN DE DATOS SQL

J LIMPIEZA E INSERCIÓN DE DATOS XML LIMPIEZA E INSERCIÓN
DE DATOS TXT

CREACIÓN DE LA BASE DE DATOS EN MYSQL

BBDD

```
1    CREATE DATABASE proyecto_1_equipo_1;
2
3    USE proyecto_1_equipo_1;
```

TABLA XML

```
CREATE TABLE data_xml (
index_xml INT NOT NULL AUTO_INCREMENT,
time` VARCHAR(255),
age VARCHAR(255),
gender VARCHAR(255),
index_sql INT NOT NULL,
PRIMARY KEY (index_xml),
CONSTRAINT fk_tabla_sql_tabla_xml
FOREIGN KEY (index_sql)
REFERENCES tabla_sql (index_sql) ON DELE
```

TABLA SQL

```
CREATE TABLE data_sql (
    index_sql INT NOT NULL AUTO_INCREMENT,
    q10_part_1 VARCHAR(255),
    q10_part_2 VARCHAR(255),
    q10_part_3 VARCHAR(255),
    q10_part_4 VARCHAR(255),
10
    q10_part_5 VARCHAR(255),
11
    q10_part_6 VARCHAR(255),
12
    q10_part_7 VARCHAR(255),
    q10_part_8 VARCHAR(255),
14
    q10_part_9 VARCHAR(255),
15
    q10_part_10 VARCHAR(255),
16
    q10_part_11 VARCHAR(255),
17
    q10_part_12 VARCHAR(255),
18
    q10_part_13 VARCHAR(255),
19
    q10_part_14 VARCHAR(255),
20
    q10_part_15 VARCHAR(255),
    q10_part_16 VARCHAR(255),
22
    d482xta VARCHAR(255),
23
    PRIMARY KEY (index_sql));
24
```

TABLA TXT

```
CREATE TABLE data_txt (
    index_txt INT NOT NULL AUTO_INCREMENT,
    index_sql INT NOT NULL,
    q3 VARCHAR(255),
    q4 VARCHAR(255),
    q5 VARCHAR(255),
    q6 VARCHAR(255),
    q7 VARCHAR(255),
    q8 VARCHAR(255),
    q9 VARCHAR(255),
     q11 VARCHAR(255),
     q12 VARCHAR(255),
    q13 VARCHAR(255),
    q14 VARCHAR(255),
51
    q15 VARCHAR(255),
    q16 VARCHAR(255),
    q17 VARCHAR(255),
    q20 VARCHAR(255),
    q21 VARCHAR(255),
    q22 VARCHAR(255),
57
    q23 VARCHAR(255),
    q24 VARCHAR(255),
     q25 VARCHAR(255),
    q26 VARCHAR(255),
    q32 VARCHAR(255),
    q33 VARCHAR(255),
    q34 VARCHAR(255),
    q35 VARCHAR(255),
    q41 VARCHAR(255),
66
    PRIMARY KEY (index_txt),
     CONSTRAINT fk_data_sql_data_txt
68
    FOREIGN KEY (index_sql)
    REFERENCES data_sql (index_sql) ON DELETE CASCADE ON UPDATE CASCADE);
```

CREACIÓN DE LA BASE DE DATOS EN PYTHON

BBDD

```
import re
import os
import xml.etree.ElementTree as ET
import mysql.connector
import pandas as pd
```

```
crear_bbdd("proyecto_1_equipo_1")
```

Se ha creado la BBDD proyecto_1_equipo_1 correctamente. True

TABLAS

```
# Esta función nos permite crear tablas en la base de datos
def creacion tablas(query):
    cnx = mysql.connector.connect(user='root', password='AlumnaAdalab',
                                host='127.0.0.1', database= 'proyecto_1_equipo_1')
    mycursor = cnx.cursor()
   try:
       mycursor.execute(query)
       cnx.commit()
       print(mycursor)
    except mysql.connector.Error as err:
       print(err)
       print("Error Code:", err.errno)
       print("SQLSTATE", err.sqlstate)
       print("Message", err.msg)
    else:
       mycursor.close()
       cnx.close()
```

```
creacion_tablas(data_xml)
```

CMySQLCursor: CREATE TABLE IF NOT EXISTS data_xml(

INSERCIÓN Y LIMPIEZA DE DATOS SQL EN MYSQL

INSERCIÓN

```
USE proyectol team1;
 -- MySQL dump 10.13 Distrib 8.0.25, for Linux (x86 64)
   -- Host: localhost
                                                                                                                                                                                                            Database: project1
                                                                                                                                                                                                                               8.0.29-0ubuntu0.21.10.2
      -- Server version
/*!40101 SET @OLD CHARACTER SET CLIENT=@@CHARACTER SET CLIENT */;
/*!40101 SET @OLD CHARACTER SET RESULTS=@@CHARACTER SET RESULTS */;
/*!40101 SET @OLD COLLATION CONNECTION=@@COLLATION CONNECTION */;
/*!50503 SET NAMES utf8 */;
/*!40103 SET @OLD TIME ZONE=@@TIME ZONE */;
/*!40103 SET TIME ZONE='+00:00' */;
/*!40014 SET @OLD UNIQUE CHECKS=@@UNIQUE CHECKS, UNIQUE CHECKS=0 */;
/*!40014 SET @OLD FOREIGN KEY CHECKS=@@FOREIGN KEY CHECKS, FOREIGN KEY CHECKS=0 */;
/*!40101 SET @OLD SQL MODE=@@SQL MODE, SQL MODE='NO AUTO VALUE ON ZERO' */;
/*!40111 SET @OLD SQL NOTES=@@SQL NOTES, SQL NOTES=0 */;
   -- Dumping data for table `tabla sql`
LOCK TABLES `tabla sql` WRITE;
/*!40000 ALTER TABLE `tabla sql` DISABLE KEYS */;
INSERT INTO `tabla sql` VALUES (1, 'Kaggle Notebooks', 'Colab
Notebooks', 'ERROR', 
Notebooks', 'ERROR', 
Notebooks', 'ERROR', 
 (4, 'ERROR', 'Goog
 Notebooks', 'ERROR', 
 Notebooks', 'ERROR', 'ERROR', 'ERROR', 'ERROR', 'ERROR', 'ERROR', 'ERROR', 'ERROR', 'Google Cloud
 ','ERROR','ERROR','ERROR','ERROR','ERROR','ERROR','ERROR','ERROR'),(7,' Kaggle
Notebooks', 'ERROR', 
Notebooks', 'ERROR', 
Notebooks', 'ERROR', 
 (10, 'ERROR', 'ERROR'
```

LIMPIEZA

20

```
USE proyecto_1_equipo_1;
UPDATE data_sql SET q10_part_1= "NULL" WHERE q10_part_1= "ERROR";
UPDATE data_sql SET q10_part_2= "NULL" WHERE q10_part_2= "ERROR";
UPDATE data_sql SET q10_part_3= "NULL" WHERE q10_part_3= "ERROR";
UPDATE data_sql SET q10_part_4= "NULL" WHERE q10_part_4= "ERROR";
UPDATE data_sql SET q10_part_5= "NULL" WHERE q10_part_5= "ERROR";
UPDATE data_sql SET q10_part_6= "NULL" WHERE q10_part_6= "ERROR";
UPDATE data_sql SET q10_part_7= "NULL" WHERE q10_part_7= "ERROR";
UPDATE data_sql SET q10_part_8= "NULL" WHERE q10_part_8= "ERROR";
UPDATE data_sql SET q10_part_9= "NULL" WHERE q10_part_9= "ERROR";
                    q10_part_10= "NULL" WHERE q10_part_10= "ERROR";
UPDATE data_sql SET
UPDATE data_sql SET
                    q10_part_11= "NULL" WHERE q10_part_11= "ERROR";
UPDATE data_sql SET
                    q10_part_12= "NULL" WHERE q10_part_12= "ERROR";
                    q10_part_13= "NULL" WHERE q10_part_13= "ERROR";
UPDATE data_sql SET
UPDATE data sql SET
                    q10_part_14= "NULL" WHERE q10_part_14= "ERROR";
UPDATE data_sql SET
                    q10_part_15= "NULL" WHERE q10_part_15= "ERROR";
UPDATE data_sql SET
                    q10_part_16= "NULL" WHERE q10_part_16= "ERROR";
UPDATE data_sql SET q10_other= "NULL" WHERE q10_other= "ERROR";
```

	index_sql	q10_part_1	q10_part_2	q10_part_3	q10_part_4	q10_part_5	q10_part_6	q10_part_7	q10_part_8	q10_part_9	q10_part_10	q10_part_11
•	1	Kaggle Notebooks	Colab Notebooks	NULL	NULL							
	2	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	3	NULL	Colab Notebooks	NULL	NULL							
	4	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	Google Clou
	5	NULL	Colab Notebooks	NULL	NULL							
	6	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	Google Cloud	NULL
	7	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	8	Kaggle Notebooks	Colab Notebooks	NULL	NULL							
	9	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	10	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	11	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	12	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	13	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	14	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	15	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	16	Kaggle Notebooks	Colab Notebooks	NULL	NULL							
	17	NULL	Colab Notebooks	NULL	NULL	Binder / J	NULL	NULL	NULL	NULL	NULL	NULL
	18	Kaggle Notebooks	Colab Notebooks	NULL	NULL							
	19	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	20	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	21	Kaggle Notebooks	Colab Notebooks	NULL	NULL							
	22	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	23	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	24	Kaggle Notebooks	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	Google Clou
	25	NULL	Colab Notebooks	NULL	NULL							
	26	Kaggle Notebooks	Colab Notebooks	NULL	NULL							
	27	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	28	Kaggle Notebooks	Colab Notebooks	NULL	NULL							
	29	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	30	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
	31	NULL	Colab Notebooks	NULL	NULL							
	00	KII II I	KILILI	KILILI	KILILI	KIL II I	KILILI	KILIL I	KILILI	KILIL I	KILILI	Casala Olavi

CREACIÓN DE CLASE Y LECTURA DE DATOS XML EN PYTHON

```
import re
import os
import xml.etree.ElementTree as ET
import mysql.connector
import pandas as pd
class Datos_xml:
# Esta clase almacenará la función para leer y limpiar los datos xml.
# Como parámetro recibirá el nombre del archivo.
    def init (self, nombre archivo):
        self.nombre_archivo = nombre_archivo
    def lectura xml(self):
        tree = ET.parse(self.nombre archivo)
        root = tree.getroot()
        self.xml lista = []
        for child in root:
            xml dict = {}
           for subchild in child:
                xml dict[subchild.tag] = subchild.text
            self.xml_lista.append(xml_dict) # Es una lista que contiene diccionarios
       return self.xml lista
```

LIMPIEZA DE DATOS XML EN PYTHON

```
def actualización género(self,xml lista):
# Esta función actualiza los datos de la columna género.
# Como argumento recibe la variable creada con el método lectura xml.
   self.xml lista = xml lista
   for i in xml lista:
       if i["gender"] == '0':
           i["gender"] = "Man"
       elif i["gender"] == '1':
           i["gender"] = "Woman"
       elif i["gender"] == '2':
           i["gender"] = "Nonbinary"
       elif i["gender"] == '3':
           i["gender"] = "Prefer not to say"
        elif i["gender"] == '4':
           i["gender"] = "Prefer to self-describe"
   return xml lista
```

```
archivo_xml = Datos_xml ("data_xml.xml")

lectura_xml = archivo_xml.lectura_xml()

genero_xml = archivo_xml.actualización_género(lectura_xml)

archivo_xml_limpio = archivo_xml.limpieza_datos(genero_xml)
```

```
def limpieza datos(self,xml lista):
# Con esta función se preparan los datos para su inserción:
# Como argumento recibe la variable creada con el método atualización genero.
    self.xml lista = xml lista
    # Eliminar la primera columna
       for i in xml lista:
           i.pop("level 0")
           i["index"] = int(i["index"])
    except: pass
    # Convertir los datos de la columna index en tipo integer
    try:
        for i in xml lista:
           i["index"] = int(i["index"])
    except: pass
    # Aplicar la condición if para evitar problemas con index sql, se aplica e.
   try:
       for i in xml lista:
            if (xml lista[0] != "index sql"):
               i.setdefault("index sql", int(i["index"]))
    except: pass
    # Convertir los datos en una lista de tuplas.
    tupla xml = []
    for i in xml lista:
       tupla xml.append(tuple(i.values()))
    return tupla xml
```

INSERCIÓN DE DATOS XML EN PYTHON

```
class Insertar datos xml:
# Esta clase creará una instancia para la inserción de los datos limpios de los arhivos .xml.
# Como argumento recibirá el nombre del archivo de xml limpio (archivo xml limpio).
    def __init__(self, fichero_xml):
        self.fichero xml = fichero xml
    def insercion datos(self):
        # Con esta función se insertan los datos limpios del fichero xml wn la tabla xml de la Base de datos.
        # No requiere parámetro.
        cnx = mysql.connector.connect(user='root', password='AlumnaAdalab',
                                    host='127.0.0.1', database= "proyecto_1_equipo_1")
        cursor = cnx.cursor()
        query_xml = "INSERT INTO data_xml(index_xml, `time`, age, gender, index_sql) VALUES (%s, %s, %s, %s, %s);"
            cursor.execute("SET GLOBAL FOREIGN_KEY_CHECKS=0;") # Se desactiva temporalmente la foreign key
            cursor.executemany (query xml, self.fichero xml )
            cnx.commit()
            print(cursor.rowcount, "registros insertados correctamente.")
            cursor.execute("SET GLOBAL FOREIGN KEY CHECKS=1;") # Se reactiva la foreign key
        except mysql.connector.Error as err:
            print(err)
            print("Error Code:", err.errno)
            print("SQLSTATE", err.sqlstate)
            print("Message", err.msg)
        cursor.close()
        cnx.close()
insercion_xml = Insertar_datos_xml(archivo_xml_limpio)
insercion xml.insercion datos()
25972 registros insertados correctamente.
```

	index_xml	time	age	gender	index_sql	
•	2	784	50-54	Man	1	
	3	924	22-24	Man	2	
	4	575	45-49	Man	3	
	5	781	45-49	Man	4	
	6	1020	25-29	Woman	5	
	7	141	18-21	Woman	6	
	8	484	30-34	Man	7	
	9	1744	22-24	Man	8	
	10	655	30-34	Man	9	
	11	1777	40-44	Man	10	
	12	3081	18-21	Woman	11	
	13	1922	18-21	Woman	12	
	14	852	45-49	Man	13	
	15	838		Man	14	
	16	563	35-39	Man	15	
	17	1315	50-54	Man	16	
	18	479	18-21	Man	17	
	19	249	22-24	Man	18	
	20	650	30-34	Man	19	
	21	1461	70+	Man	20	
	22	551	25-29	Woman	21	
	23	258	30-34	Man	22	
	24	773	35-39	Man	23	
	25	630	18-21	Man	24	
	26	2467	25-29		25	
	27	7750	45-49		26	
	28	607	22-24	Man	27	
1	29	525	22-24	Woman	28	

CREACIÓN DE CLASE Y LECTURA DE DATOS TXT EN PYTHON

CLASE Y LECTURA

```
import re
import os
import xml.etree.ElementTree as ET
import mysql.connector
import pandas as pd
```

```
class Datos_txt:
    def __init__ (self,txt):
        self.txt=txt

#Función para leer el archivo txt

def abrir_txt(self):
    with open(f'{self.txt}','r') as file:
        file_txt = file.readlines() # Es una
    return file_txt
```

```
def limpieza txt(self, lista):
        for i in lista:
            lista[lista.index(i)] = lista[lista.index(i)].replace("null","NULL").replace("<","under").replace("\n","").split(";")</pre>
        for i in lista:
            for n in i:
                i[i.index(n)] = n.strip()
        contador = 0
        for i in lista:
            i.insert(1,contador)
            contador +=1
                i[0] = int(i[0])
            except:
                continue
                                                                                        datos_txt = Datos_txt('data_txt.txt')
        tupla txt = [tuple(i) for i in lista]
                                                                                        lectura_txt = datos_txt.abrir_txt()
        tupla txt.pop(0)
        return tupla txt
                                                                                        txt limpios = datos txt.limpieza txt(lectura txt)
```

LIMPIEZA

INSERCIÓN DE DATOS TXT EN PYTHON

```
class Insertar datos txt:
# Esta clase creará una instancia para la inserción de los datos limpios de los arhivos .txt.
# Como argumento recibirá el nombre del archivo de xml limpio (txt_limpios).
    def _ init_ (self,txt):
        self.txt = txt
    def insertar datos txt(self):
    # Con esta función se insertan los datos limpios del fichero txt en la tabla data txt de la Base de datos.
    # No requiere parámetro.
       cnx = mysql.connector.connect(user='root', password='AlumnaAdalab',
                                 host='127.0.0.1', database='proyecto 1 equipo 1')
        mycursor = cnx.cursor()
        datos = """ INSERT INTO data_txt(index_txt, index_sql, q3, q4, q5, q6, q7, q8, q9, q11, q12, q13, q14, q15, q16, q17, q20, q21, q2
                              try:
           mycursor.execute("SET FOREIGN KEY CHECKS=0;") # Se desactiva temporalmente la foreign key
           mycursor.executemany(datos, self.txt)
           cnx.commit()
           print(mycursor.rowcount, "registro/s insertado/s.")
           mycursor.execute("SET FOREIGN KEY CHECKS=1;") # Se reactiva la foreign key
        except mysql.connector.Error as err:
           print(err)
           print("Error Code:", err.errno)
           print("SQLSTATE", err.sqlstate)
           print("Message", err.msg)
insercion txt = Insertar datos txt(txt limpios)
insercion_txt.insertar_datos_txt()
25972 registro/s insertado/s.
```

ļi	ndex_txt	index_sql	q3	q4	q 5	q6	q7	q8	q9
▶ 1		1	Indonesia	Master's degree	Program/Project Manager	20+ years	NULL, SQL, C, C++, Java	Python	NULL, Notepad-
2	!	2	Pakistan	Master's degree	Software Engineer	1-3 years	Python, C++, Java	Python	NULL, PyCharm
3		3	Mexico	Doctoral degree	Research Scientist	20+ years	Python	Python	NULL, Spyder,
4		4	India	Doctoral degree	Other	under 1 years	Python, C, MATLAB	Python	NULL, Spyder,
5		5	India	I prefer not to answer	Currently not employed	under 1 years	Python	Python	Jupyter (JupyterL
6		6	India	Some college/university study without earning a	Student	1-3 years	NULL, C++, Java, Javascript	Python	NULL, Visual Stu
7	'	7	India	Bachelor's degree	Data Scientist	5-10 years	Python	Python	NULL, Jupyter N
8		8	Russia	Bachelor's degree	Currently not employed	3-5 years	Python, SQL	Python	NULL, Other
9		9	Turkey	I prefer not to answer	Other	1-3 years	Python, SQL	SQL	NULL, Spyder,
1	0	10	Australia	Doctoral degree	Other	1-3 years	Python, R, SQL	R	NULL, RStudio,
1	1	11	India	Master's degree	Student	under 1 years	Python, R, C++	R	NULL, RStudio,
1	2	12	India	Master's degree	Student	under 1 years	Python, MATLAB	Python	NULL, RStudio,
1	3	13	Nigeria	Master's degree	Program/Project Manager	5-10 years	Python, SQL	Python	NULL, Spyder,
1	4	14	Nigeria	Bachelor's degree	Other	under 1 years	Python	Python	NULL, Visual Stu
1	5	15	Greece	Doctoral degree	Research Scientist	10-20 years	Python, C, C++, MATLAB	Python	NULL, Spyder
1	6	16	Belgium	Bachelor's degree	Data Analyst	20+ years	Python, SQL	Python	Jupyter (JupyterL
1	7	17	Pakistan	Bachelor's degree	Data Scientist	1-3 years	Python, SQL	Python	Jupyter (JupyterL
1	8	18	Japan	Master's degree	Software Engineer	3-5 years	Python, SQL, C, Java, Jav	Python	Jupyter (JupyterL
1	9	19	Egypt	Bachelor's degree	Other	under 1 years	NULL, None	R	NULL, PyCharm
2	0	20	Singapore	Bachelor's degree	Other	under 1 years	Python	Python	Jupyter (JupyterL
2	1	21	Turkey	Bachelor's degree	Data Scientist	3-5 years	Python, R, SQL, C++	R	Jupyter (JupyterL
2	2	22	Indonesia	Master's degree	Student	1-3 years	NULL, R	R	NULL, RStudio
2	3	23	Brazil	Master's degree	Machine Learning Engin	20+ years	Python, SQL, C++	SQL	NULL, PyCharm
2	4	24	India	Bachelor's degree	Student	1-3 years	Python, R, SQL, C, C++, M	Python	NULL, RStudio,
2	5	25	Poland	Master's degree	Machine Learning Engin	3-5 years	Python, C++	Python	NULL, Visual Stu
2	6	26	Brazil	Doctoral degree	Research Scientist	under 1 years	Python, R	Python	NULL, RStudio,
2	7	27	China	Master's degree	Student	3-5 years	Python, C, C++	Python	NULL, PyCharm
2	8	28	Iran, Isl	Bachelor's degree	Data Scientist	3-5 years	Python	Python	NULL, Visual Stu
2	9	29	India	Bachelor's degree	Student	under 1 years	Python, Java	Python	NULL, PyCharm
3	0	30	India	Bachelor's degree	Other	1-3 years	Python	Python	NULL, Visual Stu
3	1	31	India	Master's degree	Data Scientist	5-10 years	Python, R, SQL	Python	NULL, Visual Stu
3	2	32	United	Some college/university study without earning a	Data Analyst	under 1 years	NULL, R	R	NULL, RStudio
3	3	33	Egypt	Bachelor's degree	Data Analyst	3-5 years	Python	R	NULL, Notepad-

